UNIVERSIDAD EAFIT ST0263 Tópicos especiales en telemática 2023-2

PROFESOR: EDWIN MONTOYA-MUNERA - emontoya@eafit.edu.co

Laboratorios de clase 3-2 y 3-3

Todos estos laboratorios se realizan en AWS ACADEMY:

LABORATOR™: □MPLEMENTAC™N DE UN DATA WAREHOUSE SENC□LLO CON AWS S3, GLUE y ATHENA.

Ver videos previos:

□ https://youtu.be/2WliTIK1ips (lab aws s3, glue, athena)

Fuentes de datos: datasets de:

https://github.com/st0263eafit/st0263-232.git

datos específicos de: onu y tickit

Ingesta de datos: manual a AWS S3

Almacenamiento: en datalake con AWS S3

Catalogación: con AWS Glue, creación de las 2 bases de datos (onudb y tickitdb) y las respectivas tablas.

Consultas: Con AWS Athena SQL realizar diferentes consultas a diferentes tablas.

LABORATORIO: IMPLEMENTACIÓN DE UN DATA WAREHOUSE CON EMR y HIVE

Seguir todas las instrucciones del laboratorio de hive en el github:

https://github.com/st0263eafit/st0263-232/tree/main/bigdata/03-hive-sparksql

LABORATORIO: IMPLEMENTACIÓN DE UN DATA WAREHOUSE CON AWS REDSHIFT Y REDSHIFT SPECTRUM

Redshift Spectrum: consultas de datos en S3 a través de Redshift: Ref: https://docs.aws.amazon.com/redshift/latest/dg/c-getting-started-using-spectrum.html

REDSHIFT

Ayudas:

https://docs.aws.amazon.com/redshift/latest/gsg/new-user.html https://docs.aws.amazon.com/redshift/latest/gsg/console.html https://docs.aws.amazon.com/redshift/latest/gsg/data-loading.html

Fuentes de datos: datasets de:

https://github.com/st1800eafit/st1800-232.git

datos específicos de: tickit

https://docs.aws.amazon.com/redshift/latest/gsg/samples/tickitdb.zip


Ingesta de datos: manual


Almacenamiento: Redshift, cargar la base de datos ejemplo que trae redshift: tickit. Se deja como reto el crear la misma base de datos tickit desde archivos planos ubicados en S3 (ver fuentes de datos)


Consultas: diversas consultas en sql con base de datos ejemplo incluido (tickit).


Crear un cluster y ejecutar consultas básicas en la base de datos demo 'tickit':




































10. Terminó

// WARNING..... RECUERDE QUE DEBE PAUSAR O BORRAR EL CLÚSTER SINO VA A TRABAJAR MÁS, PORQUE SEGUIRÁ COBRANDO AÚN TERMINANDO EL LAB DE AWS ACADEMY



REDSHIFT SPECTRUM

1. Crear un rol AM para Amazon Redshift


- 1. Abrir la **consola** DAM.
- 2. En el panel de navegación, escoger Roles.
- 3. Escoger Create role.
- 4. Escoger AWS service, y luego escoger Redshift.
- Bajo Select your use case, escoger Redshift Customizable y luego escoger Next: Permissions.
- 6. La página **Attach permissions policy** va a aparecer. Escoja AmazonS3ReadOnlyAccess y AWSGlueConsoleFullAccess,y AmazonAthenaFullAcces s. Escoja **Next: Review**.
- En Role name, entre myspectrum_role
- 2. Revisar información, y luego **Create role**.
- 3. En el panel **Roles**. Escoja el rol que acaba de crear y luego copie el **Role ARN** al clipboard. Este ARN será utilizado cuando cree la table externa en Amazon S3.

En la cuenta de AWS Academy, NO PERMITE CREAR Usuarios, Grupos, ni Roles, así que le saldrá este error:




Pero para efectos de crear la tabla externa en Redshift Spectrum, puede usar el Role predeterminado: 'LabRole', paso ya realizado en la instalación del Clúster 'redshift-cluster-1'

Actualice el URN del LabRole, esto lo encuentra por el servicio 🖾 M, búsque LabRole y copie el nuevo URN:



Nuevo ARN: arn:aws:iam::433075868803:role/LabRole

En el editor SQL v2:



2. Crear la base de datos externa:

create external schema myspectrum_schema from data catalog database 'myspectrum_db' iam_role 'arn:aws:iam::433075868803:role/LabRole' create external database if not exists;

3. Crear una table con datos externos en S3:

create external table myspectrum_schema.sales(salesid integer, listid integer, sellerid integer, buyerid integer, eventid integer, dateid smallint, gtysold smallint, pricepaid decimal(8,2), commission decimal(8,2), saletime timestamp) row format delimited fields terminated by '\t' stored as textfile location 's3://emontoyadatalake1/datasets/tickitdb2/sales/' table properties ('numRows'='172000');

4. Consultar datos:

select count(*) from myspectrum_schema.sales;

5. Crear una tabla nativa en redshit para combinarla con la tabla externa en un query:

create table event2(

¹ Coloque su propio bucket

eventid integer not null distkey, venueid smallint not null, catid smallint not null, dateid smallint not null sortkey, eventname varchar(200), starttime timestamp);

6. Cargar datos en la table 'event2':

COPY event2 FROM 's3://emontoyadatalake/datasets/tickitdb2/events/allevents.txt' iam_role 'arn:aws:iam::433075868803:role/LabRole' delimiter '|' timeformat 'YYYY-MM-DD HH:MISS' region 'us-east-1';

7. Realizar una consulta con tablas externas y nativas:

select top 10 myspectrum_schema.sales.eventid, sum(myspectrum_schema.sales.pricepaid) from myspectrum_schema.sales, event2 where myspectrum_schema.sales.eventid = event2.eventid and myspectrum_schema.sales.pricepaid > 30 group by myspectrum_schema.sales.eventid order by 2 desc;

// WARNING..... RECUERDE QUE DEBE PAUSAR O BORRAR EL CLÚSTER SINO VA A TRABAJAR MÁS, PORQUE SEGUIRÁ COBRANDO AÚN TERMINANDO EL LAB DE AWS ACADEMY